

Projekt naukowo - wdrożeniowy I

**Modelowanie temperatury i wilgotności
względnej na podstawie rozproszonych
danych światłowodowych z wykorzystaniem
metod uczenia maszynowego**

7 marca 2026

Spis treści

1	Cel projektu	2
2	Dane wejściowe i zmienne docelowe	2
3	Budowa datasetu analitycznego	2
4	Preprocessing danych	3
5	Zadania modelowe	4
6	Modele bazowe i zaawansowane	4
7	Podział danych i kontrola leakage	5
8	Metryki oceny	5
9	Walidacja modeli	6
10	Interpretowalność i wymagania Trusted AI	6
11	Oczekiwane wyniki końcowe	7
12	Mapowanie: dane, analizy, modele, metryki i wynik	7

1. Cel projektu

Celem projektu jest opracowanie analityczno-modelowego systemu wyznaczania temperatury oraz wilgotności względnej na podstawie danych rozproszonych pochodzących z dwóch równoległych kanałów światłowodowych: kanału referencyjnego o dominującej czułości temperaturowej oraz kanału poliimidowego o odpowiedzi zależnej od temperatury i wilgotności. Projekt ma charakter wielozadaniowy i obejmuje zarówno modelowanie stanów statycznych, jak i analizę stanów przejściowych, efektów pamięciowych, histerezy oraz odporności modeli na zmianę trajektorii warunków.

Zakres prac studenckich obejmuje sześć komplementarnych zadań: regresję temperatury, regresję wilgotności względnej, regresję wielowyjściową $[T, RH]$, klasyfikację reżimu pracy układu, detekcję anomalii i dropoutów oraz analizę przestrzenno-czasowej odpowiedzi sensora. Celem nadrzędnym nie jest wyłącznie minimalizacja błędu predykcji, lecz budowa modeli zachowujących poprawność, stabilność i przewidywalność również w warunkach nieobecnych w zbiorze uczącym, zwłaszcza na trajektoriach przejściowych, rampach oraz przebiegach z histerezą.

Projekt ma również charakter metodologiczny w obszarze Trusted / Trustworthy AI. Oznacza to konieczność jawnego raportowania ograniczeń modeli, kontroli leakage, oceny generalizacji między sesjami i warunkami pracy, a także zapewnienia interpretowalności i reprodukowalności całego pipeline'u analitycznego.

2. Dane wejściowe i zmienne docelowe

Dane wejściowe obejmują sygnały przestrzenno-czasowe z dwóch kanałów pomiarowych: CH1_REF_T oraz CH2_PI_TRH. Dla każdego rekordu dostępne są ponadto znaczniki czasu, indeksy położenia gage'y lub segmentów przestrzennych, metadane eksperymentalne oraz wskaźniki jakości sygnału, w tym quality factor i spectral shift quality. Struktura danych umożliwia analizę zarówno w reprezentacji segmentowej, jak i w reprezentacji pełnego profilu przestrzenno-czasowego.

Zmienne docelowe obejmują wartości temperatury i wilgotności względnej w dwóch postaciach: jako wielkości chwilowe oraz jako wartości średnie wyznaczone w stabilnych oknach czasowych. Dodatkowo wykorzystuje się etykiety reżimu pracy, obejmujące co najmniej klasy: stan stabilny, stan przejściowy, relaksacja oraz histereza. W zadaniach specjalistycznych mogą być stosowane również etykiety kierunku dojścia do punktu pracy, zwłaszcza w analizie histerezy.

Dane walidacyjne obejmują wysokorozdzielcze profile referencyjne oraz zestawy eksperymentów przeznaczone do oceny generalizacji, pamięci i odporności modeli. Szczególne znaczenie mają: zbiór trajektorii mieszanych i ramp jako główny test uogólniania, zbiory histerezy i relaksacji jako test efektów pamięciowych oraz wysokorozdzielcze profile jakościowe jako punkt odniesienia dla wiarygodności fizycznej wyników.

3. Budowa datasetu analitycznego

Budowę datasetu należy rozpocząć od integracji plików manifestu eksperymentów, konfiguracji eksperymentu oraz definicji okien stabilnych. Scalanie danych powinno być realizowane z użyciem wspólnych identyfikatorów eksperymentu, powtórzenia, kanału oraz znacznika czasu.

Wynikiem tego etapu ma być spójna baza danych umożliwiająca jednoznaczne powiązanie sygnału wejściowego z warunkami eksperymentu i odpowiadającymi im targetami.

Dla danych rozproszonych należy zbudować reprezentację w postaci tablicy czas $\backslash times$ pozycja $\backslash times$ kanał. Następnie należy ograniczyć analizę do aktywnego odcinka analitycznego i wykluczyć strefy brzegowe, w tym końcowy obszar sensora, który nie dostarcza pełnowartościowych informacji i może generować artefakty. Segment referencyjny powinien zostać zachowany jako osobny obszar roboczy wykorzystywany do korekcji offsetu i wyrównania między seriami.

Na podstawie jawnie zdefiniowanych okien czasowych należy oznaczyć obserwacje jako stabilne, przejściowe lub relaksacyjne. Dane z logów środowiskowych należy wykorzystać do wyznaczenia targetów chwilowych oraz średnich w oknach ustalonych. Wysokorozdzielcze profile walidacyjne powinny zostać zachowane jako odrębny komponent zbioru, zawierający zarówno profile sygnału, jak i cechy jakościowe.

Końcowo należy utworzyć co najmniej dwa zasadnicze datasety: `dataset_static`, obejmujący obserwacje ze stabilnych okien pracy, oraz `dataset_dynamic`, obejmujący trajektorie, przejścia i relaksacje. Taki podział jest konieczny, ponieważ modele przeznaczone do analizy stanów statycznych i modele przeznaczone do analizy sekwencyjnej odpowiadają odmiennym własnościom danych.

4. Preprocessing danych

Preprocessing musi obejmować synchronizację czasową wszystkich źródeł danych, tak aby sygnały z kanałów pomiarowych, profile walidacyjne oraz dane środowiskowe były osadzone na wspólnej osi czasu. Bez tego nie można zapewnić zgodności między obserwacjami wejściowymi a zmiennymi docelowymi.

Kolejnym krokiem jest filtrowanie dropoutów, wartości nieoznaczonych i rekordów o niskiej jakości korelacji. Wskaźniki jakości sygnału należy traktować jako pełnoprawne zmienne pomocnicze w preprocessingu oraz jako potencjalne źródło etykiet dla zadania detekcji anomalii. Usunięcie punktów niepewnych jest konieczne zarówno dla stabilności modeli, jak i dla poprawności oceny ich błędu.

Następnie należy wyeliminować strefy brzegowe oraz jawnie ograniczyć analizę do aktywnego zakresu przestrzennego. W dalszym etapie należy wykonać korekcję globalnego offsetu. Dla każdej próbki należy wyznaczyć średnią po segmencie referencyjnym w obu kanałach i odjąć ją od całego aktywnego profilu danego kanału. Operacja ta pełni funkcję wyrównania między seriami, redukuje wspólny składnik instrumentalny oraz ogranicza wpływ zmian bazowych niezwiązanych bezpośrednio z analizowaną odpowiedzią sensora.

Wymagana jest również normalizacja między seriami i replikami, aby ograniczyć wpływ dryfu bazowego między dniami i sesjami. Po synchronizacji i korekcji należy przeprowadzić segmentację na próbki analityczne, przy czym okna stabilne, okna przejściowe oraz okna relaksacyjne nie mogą być mieszane bez jawnej etykiety reżimu.

W odniesieniu do reprezentacji cech należy stosować dwa poziomy opisy. Poziom pierwszy obejmuje cechy zagregowane, takie jak średnie, odchylenia standardowe, różnice międzykanałowe, lokalne gradienty przestrzenne oraz miary stabilności. Poziom drugi obejmuje reprezentację przestrzenno-czasową lub sekwencyjną, niezbędną do modelowania relaksacji, pamięci i histerezy.

W razie potrzeby należy zastosować redukcję wymiaru, aby kontrolować złożoność modelu i ograniczać ryzyko przeuczenia.

5. Zadania modelowe

Zadanie 1 — regresja statyczna temperatury i wilgotności względnej

Pierwszym zadaniem jest regresja statyczna temperatury i wilgotności względnej. Wejściem są cechy wyznaczone z okien stabilnych, a wyjściem odpowiednio temperatura, wilgotność lub para wartości $[T, RH]$. Celem tego zadania jest uzyskanie możliwie najlepszej dokładności w punktach ustalonych.

Zadanie 2 — regresja dynamiczna

Drugim zadaniem jest regresja dynamiczna, w której wejściem są sekwencje czasowe lub zestawy cech opisujących przebieg przejściowy, natomiast wyjściem są przebiegi $T(t)$ i $RH(t)$. Zadanie to ma umożliwić poprawne działanie modeli na rampach, skokach, relaksacji i trajektoriach mieszanych.

Zadanie 3 — klasyfikacja reżimu pracy

Trzecim zadaniem jest klasyfikacja reżimu pracy. Model powinien rozróżniać co najmniej klasy: stabilny, przejściowy, relaksacja oraz histereza. Klasyfikacja reżimu ma znaczenie nie tylko deskryptywne, lecz również funkcjonalne, ponieważ może być używana do warunkowego uruchamiania odpowiedniego modelu regresyjnego.

Zadanie 4 — detekcja anomalii

Czwartym zadaniem jest detekcja anomalii. W tej części należy identyfikować rekordy niewiarygodne, obciążone słabą jakością sygnału, niestabilnością przestrzenną lub obecnością dropoutów. Celem nie jest jedynie klasyfikacja anomalii, lecz również ochrona jakości danych wejściowych dla pozostałych zadań modelowych.

Zadanie 5 — analiza histerezy

Piątym zadaniem jest analiza histerezy. Należy porównywać odpowiedzi dla tych samych wartości temperatury i wilgotności względnej osiąganych przy różnej historii dojścia. Wynikiem może być zarówno estymacja błędu histerezy, jak i klasyfikacja kierunku dojścia do stanu.

Zadanie 6 — analiza wpływu struktury przestrzenno-czasowej sygnału

Szóstym zadaniem jest analiza wpływu struktury przestrzenno-czasowej sygnału na wartość predykcyjną modeli. Należy odpowiedzieć na pytanie, czy profile lokalne i ich dynamika rzeczywiście niosą informację wykraczającą poza prosty opis średniej odpowiedzi dwóch kanałów.

6. Modele bazowe i zaawansowane

W pierwszej kolejności należy zastosować modele bazowe, obejmujące regresję liniową jedno- i wielowyjściową oraz modele regularyzowane typu ridge i lasso. Modele te stanowią punkt

odniesienia zarówno dla interpretowalności, jak i dla oceny, czy zależności między wejściami i targetami mają charakter zbliżony do liniowego.

W grupie modeli klasycznych należy rozważyć metody drzewiaste i jądrowe, w szczególności Random Forest Regressor, Gradient Boosting lub model zbliżony funkcjonalnie do XGBoost oraz SVR trenowany osobno dla temperatury i wilgotności względnej. Modele te są przydatne do uchwycenia nieliniowości i interakcji między cechami bez konieczności dysponowania bardzo dużym zbiorem danych.

W grupie modeli bardziej zaawansowanych należy uwzględnić MLP dla cech zagregowanych, 1D CNN lub Temporal CNN dla sekwencji oraz lekki model rekurencyjny typu LSTM lub GRU dla `dataset_dynamic`. Modele te są szczególnie istotne w analizie relaksacji, pamięci i trajektorii nieuczących.

W zadaniach detekcji anomalii należy rozważyć Isolation Forest, One-Class SVM oraz prosty autoenkoder wykorzystywany do reprezentacji przestrzennej i oceny odstępstw od typowej odpowiedzi sensora.

Porównanie modeli ma mieć charakter naukowy i powinno odpowiadać na pytanie, jaka klasa reprezentacji danych i jaka złożoność modelu są rzeczywiście uzasadnione przez strukturę badanego problemu.

7. Podział danych i kontrola leakage

Podział danych musi być zorganizowany według eksperymentów, sesji i warunków pracy, a nie według pojedynczych rekordów. Próbkę pochodzącą z tej samej serii lub z tego samego stabilnego kroku nie mogą jednocześnie występować w zbiorze uczącym i testowym, ponieważ prowadziłoby to do silnego leakage czasowego i zawyżenia wyników.

Zbiór uczący powinien opierać się przede wszystkim na danych statycznych oraz części replik. Zbiór walidacyjny powinien obejmować pozostałe repliki oraz wydzielone fragmenty eksperymentów pamięciowych. Zbiór testowy powinien zawierać przede wszystkim trajektorie mieszane, dane wysokorozdzielcze walidacyjne oraz wydzieloną część eksperymentów relaksacyjnych.

Należy również przeprowadzać scenariusze oceny, w których z uczenia wyłączane są całe poziomy temperatury lub wilgotności względnej. Pozwala to ocenić zdolność modeli do interpolacji i częściowej ekstrapolacji. W badaniach histerezy należy dodatkowo testować modele na przebiegach o przeciwnym kierunku dojścia niż te wykorzystane podczas uczenia.

Bezwzględnie zabronione jest losowanie pojedynczych okien z jednej silnie skorelowanej sekwencji do różnych subsetów danych. Kontrola leakage jest jednym z kluczowych wymogów Trusted AI w tym projekcie.

8. Metryki oceny

Dla zadań regresyjnych należy raportować co najmniej MAE, RMSE, współczynnik determinacji R^2 oraz maksymalny błąd bezwzględny w zbiorze testowym. RMSE jest istotne z perspektywy porównania z prostszymi wariantami projektu, MAE lepiej opisuje błąd użytkowy, natomiast błąd maksymalny ma szczególne znaczenie w kontekście zaufania do modelu i identyfikacji sytuacji

krytycznych.

Dla klasyfikacji reżimu należy raportować accuracy, macro F1 oraz balanced accuracy. Dla detekcji anomalii należy stosować precision, recall, F1 oraz false alarm rate. W analizie odporności modeli należy dodatkowo oceniać rozrzut metryk między sesjami, degradację jakości między zbiorem uczącym a trajektoriami testowymi oraz wrażliwość modeli na redukcję liczby pozycji przestrzennych lub na usunięcie jednego z kanałów.

Metryki nie mogą być raportowane wyłącznie globalnie. Konieczne jest ich zestawienie dla odrębnych scenariuszy: stanów stabilnych, trajektorii przejściowych, relaksacji, histerezy oraz walidacji wysokorozdzielczej.

9. Walidacja modeli

Walidacja musi mieć charakter wielowarstwowy. Należy stosować k-fold lub wariant równoważny realizowany na poziomie eksperymentów, a nie na poziomie pojedynczych rekordów. Dodatkowo należy wykonać procedury leave-one-condition-out oraz leave-one-session-out, aby sprawdzić stabilność modeli przy zmianie warunków środowiskowych oraz między sesjami.

Szczególne znaczenie ma test na trajektoriach mieszanych i rampach, ponieważ właśnie ten scenariusz weryfikuje, czy model wytrenowany na stanach ustalonych zachowuje poprawność na przebiegach nieobecnych w uczeniu. Równolegle należy przeprowadzić odrębny test na danych histerezy oraz na danych relaksacyjnych, aby ocenić wpływ pamięci układu i opóźnień odpowiedzi.

Walidacja powinna obejmować również porównanie z wysokorozdzielczymi profilami referencyjnymi oraz analizę zależności błędu od jakości korelacji sygnału. Nie wolno wykorzystywać tych samych danych jednocześnie do strojenia i końcowej oceny wiarygodności fizycznej modelu.

10. Interpretowalność i wymagania Trusted AI

Projekt wymaga pełnej reprodukowalności. Należy wersjonować dane, zapisywać wszystkie użyte splits, seedy treningu, konfiguracje preprocessingu i parametry modeli. Każdy eksperyment obliczeniowy musi być jednoznacznie odtwarzalny.

Dla modeli drzewiastych należy przeprowadzić analizę ważności cech lub analizę typu SHAP. Dla innych klas modeli należy zastosować równoważne procedury interpretacyjne, pozwalające określić, które elementy sygnału i które cechy dynamiczne mają największy wpływ na wynik predykcji.

Obowiązkowa jest analiza wrażliwości na usunięcie kanału referencyjnego lub kanału poliimidowego. Należy również zbadać zależność błędu modelu od jakości sygnału. Pozwala to ocenić, czy model zachowuje się wiarygodnie w warunkach degradacji danych wejściowych.

W raporcie końcowym muszą zostać jawnie opisane główne ryzyka metodologiczne: overfitting do konkretnej trajektorii środowiskowej, leakage między oknami tej samej serii, pozorna poprawa wyników wynikająca z ograniczenia oceny wyłącznie do stanów stabilnych oraz spadek wiarygodności w warunkach niskiej jakości korelacji. Trusted AI w tym projekcie oznacza nie tylko wysoką skuteczność, lecz również transparentność ograniczeń, przewidywalność zachowania i poprawność procedury walidacyjnej.

11. Oczekiwane wyniki końcowe

Końcowy rezultat projektu powinien obejmować reprodukowalny pipeline analityczny, prowadzący od integracji danych surowych i półprzetworzonych, przez preprocessing i konstrukcję cech, do trenowania, walidacji i porównania modeli. Wynik ten powinien być uzupełniony raportem naukowo-technicznym opisującym założenia, procedury, uzyskane metryki, ograniczenia oraz rekomendowany model końcowy.

Oczekuje się przygotowania porównania modeli na wszystkich istotnych scenariuszach walidacyjnych, w tym na stanach statycznych, trajektoriach przejściowych, histerezie, relaksacji i walidacji jakościowej. Należy wskazać model rekomendowany wraz z zakresem jego stosowalności oraz zidentyfikowanymi ograniczeniami.

Końcowym efektem projektu ma być również spójna koncepcja demonstratora analitycznego, w którym wejście stanowi pakiet danych z dwóch kanałów i danych środowiskowych, a wyjście obejmuje estymację temperatury, wilgotności względnej, klasy reżimu pracy oraz flagi jakości lub anomalii.

12. Mapowanie: dane, analizy, modele, metryki i wynik

Scenariusz 1 — dane ze stanów stabilnych

Dane ze stanów stabilnych należy przekształcić po synchronizacji, filtracji jakościowej i korekcji offsetu do postaci cech zagregowanych, takich jak średnie, odchylenia, różnice międzykanałowe i gradienty przestrzenne. Na tej podstawie należy realizować regresję temperatury i wilgotności względnej z użyciem modeli liniowych, ridge, Random Forest, Gradient Boosting oraz MLP. Oczekiwany wynik jest bazowy model statyczny oceniany za pomocą MAE, RMSE i R^2 .

Scenariusz 2 — dane replikacyjne

Dane replikacyjne należy analizować po dodatkowej normalizacji międzydniowej, koncentrując się na cechach stabilności i wariancji. Celem jest oszacowanie powtarzalności, dryfu i niepewności. W tym scenariuszu szczególnie istotne są porównania błędów między replikami oraz odporność modeli na zmianę sesji.

Scenariusz 3 — dane z pętli histerezy

Dane z pętli histerezy należy segmentować według kierunku narastania i opadania warunków. Po ekstrakcji cech pętli oraz różnic dla tych samych punktów pracy osiąganych odmienną drogą należy realizować klasyfikację kierunku oraz regresję z pamięcią. Oczekiwany wynik jest ilościowa identyfikacja histerezy temperatury i wilgotności względnej.

Scenariusz 4 — dane odpowiedzi skokowych i relaksacyjnych

Dane odpowiedzi skokowych i relaksacyjnych należy wyrównać względem czasu skoku i przekształcić do postaci cech sekwencyjnych, obejmujących pochodne, czas ustalania, przeregulowanie i inne deskryptory dynamiki. Na tej podstawie należy realizować klasyfikację reżimu i regresję dynamiczną z użyciem modeli MLP, 1D CNN oraz GRU lub LSTM. Oczekiwanym wynikiem jest model zdolny do opisu przejść i relaksacji, oceniany między innymi przez F1, RMSE i maksymalny błąd.

Scenariusz 5 — dane trajektorii mieszanych

Dane trajektorii mieszanych należy potraktować jako główny test generalizacji. Po pełnej synchronizacji i nadaniu etykiet reżimu należy wykorzystać najlepsze modele wyłonione we wcześniejszych etapach i ocenić ich zachowanie w warunkach nieuczących. Oczekiwanym wynikiem jest wiarygodna ocena odporności modelu na zmianę trajektorii i reżimu pracy.

Scenariusz 6 — dane wysokorozdzielcze i cechy jakościowe

Dane wysokorozdzielcze wraz z cechami jakościowymi należy wykorzystać do walidacji fizycznej i benchmarkingu. Analiza ma określić zgodność odpowiedzi modelowej z profilem referencyjnym oraz wpływ jakości korelacji i parametrów reprezentacji sygnału na końcowy błąd. Wynikiem ma być potwierdzenie lub ograniczenie wiarygodności fizycznej uzyskanych modeli.